

2023年度 専門科目 — 大問1 問1 解答

問題文の記号：データ点 (x_i, y_i) ($i = 1, \dots, n, n \geq 2$)。 μ_x, μ_y は平均、 σ_x, σ_y は分散(variance)、 σ_{xy} は共分散(covariance)。

※ 本問では σ_x, σ_y は分散なので、標準偏差は $\sqrt{\sigma_x}, \sqrt{\sigma_y}$ となる。定義より

$$\frac{1}{n} \sum x_i^2 = \sigma_x + \mu_x^2, \quad \frac{1}{n} \sum x_i y_i = \sigma_{xy} + \mu_x \mu_y.$$

空欄の答え一覧

ア	イ	ウ	エ	オ	カ
$(y_i - ax_i - b)^2$	$\frac{\partial E}{\partial a} = 0$	$\frac{\partial E}{\partial b} = 0$	$\frac{\sigma_{xy}}{\sqrt{\sigma_x \sigma_y}}$	$\frac{y - \mu_y}{\sqrt{\sigma_y}}$	$\frac{x - \mu_x}{\sqrt{\sigma_x}}$

(1) 空欄 ア・イ・ウ

最小二乗法は、各データ点と回帰モデル $y = ax + b$ の残差(誤差) $y_i - (ax_i + b)$ の二乗和を最小にする。よって

$$E = \sum_{i=1}^n \underbrace{(y_i - ax_i - b)^2}_{[\text{ア}]}$$

E は a, b について下に凸な二次関数だから、最小化の条件は各変数による偏微分が 0 :

$$[\text{イ}] : \frac{\partial E}{\partial a} = 0, \quad [\text{ウ}] : \frac{\partial E}{\partial b} = 0$$

(2) 連立一次方程式の構築

偏微分を実行する :

$$\frac{\partial E}{\partial a} = \sum_{i=1}^n 2(y_i - ax_i - b)(-x_i) = -2 \sum_{i=1}^n x_i(y_i - ax_i - b) = 0$$

$$\frac{\partial E}{\partial b} = \sum_{i=1}^n 2(y_i - ax_i - b)(-1) = -2 \sum_{i=1}^n (y_i - ax_i - b) = 0$$

それぞれ $\frac{1}{n}$ 倍し、平均・分散・共分散で表すと、

$$\frac{\partial E}{\partial b} = 0 \implies \boxed{\mu_y = a \mu_x + b} \quad (\text{I})$$

$$\frac{\partial E}{\partial a} = 0 \implies \frac{1}{n} \sum x_i y_i = a \cdot \frac{1}{n} \sum x_i^2 + b \cdot \frac{1}{n} \sum x_i$$

$$\implies \boxed{\sigma_{xy} + \mu_x \mu_y = a(\sigma_x^2 + \mu_x^2) + b \mu_x} \quad (\text{II})$$

この (I)(II) が a, b についての連立一次方程式 (5要素 $\mu_x, \mu_y, \sigma_x, \sigma_y, \sigma_{xy}$ で表現)。

解くと、(I) より $b = \mu_y - a\mu_x$ 。これを (II) に代入して整理すると $a\sigma_x = \sigma_{xy}$ 、よって

$$a = \frac{\sigma_{xy}}{\sigma_x}, \quad b = \mu_y - \frac{\sigma_{xy}}{\sigma_x} \mu_x.$$

(3) 空欄 エ・オ・カ

相関係数は (σ_x, σ_y が分散なので分母は標準偏差の積)

$$[\text{エ}] : \quad R = \frac{\sigma_{xy}}{\sqrt{\sigma_x} \sqrt{\sigma_y}} = \frac{\sigma_{xy}}{\sqrt{\sigma_x \sigma_y}}$$

回帰直線は $a = \frac{\sigma_{xy}}{\sigma_x}$, $b = \mu_y - a\mu_x$ より $y - \mu_y = \frac{\sigma_{xy}}{\sigma_x}(x - \mu_x)$ 。両辺を $\sqrt{\sigma_y}$ で割ると

$$\frac{y - \mu_y}{\sqrt{\sigma_y}} = \frac{\sigma_{xy}}{\sigma_x} \cdot \frac{x - \mu_x}{\sqrt{\sigma_y}} = \underbrace{\frac{\sigma_{xy}}{\sqrt{\sigma_x \sigma_y}}}_R \cdot \frac{x - \mu_x}{\sqrt{\sigma_x}}$$

したがって標準化変数 (z スコア) の関係として

$$\underbrace{\frac{y - \mu_y}{\sqrt{\sigma_y}}}_{[\text{オ}]} = R \underbrace{\frac{x - \mu_x}{\sqrt{\sigma_x}}}_{[\text{カ}]}$$

[オ] は y の要素 (y, μ_y, σ_y) のみ、[カ] は x の要素 (x, μ_x, σ_x) のみで表され、条件を満たす。